



UNIVERSITY
OF ARTIFICIAL
INTELLIGENCE

Кочетков Михаил
Николаевич


Создание тренера по python с использованием нейроинтеллекта

Дата защиты 08.05.2025

E-mail: subaka@mail.ru

Поток обучения

06.2024



padding="0" cellspacing="0" style="border: 1px solid black; width: 100%; height: 100%;">
 <div class="container" style="border: 1px solid black; width: 100%; height: 100%;">
 <div class="row" style="border: 1px solid black; width: 100%; height: 100%;">
 <div class="col" style="border: 1px solid black; width: 50%; height: 100%;">
 <div class="col" style="border: 1px solid black; width: 50%; height: 100%;">
 </div>
 </div>
 </div>
 </div>

Постан

Трене

техно

проце

персо

задан

Тренер на основе нейросетевых технологий может значительно улучшить процесс обучения, предоставляя персонализированные рекомендации и задания.

Цель

Задача заключается в разработке системы обучения по Python, которая будет использовать нейросетевые технологии для создания адаптивного тренера.



Задачи

1. Формирование структуры обучающего курса
2. Создание датасета для обучения модели
3. Обучение модели
4. Интеграция модели в систему обучения



Обучающая база



175 Books of
Programming



Какие данные взять для обучения?



1. Книги по программированию лучше подходят для глубокого изучения темы, но требуют значительных усилий для преобразования данных в структурированный формат.

2. Jupyter notebooks предоставляют удобный и компактный способ работы с данными, но их использование ограничено темами и объемом информации.

3. Синтетические датасеты обеспечивают максимальную гибкость и контроль над данными, но процесс генерации может быть медленным, а данные могут быть менее реалистичными.

Описание модели

sberbank-ai/rugpt3large_based_on_gpt2



Основные характеристики:


- **Базовая архитектура:** GPT-2, адаптированная для русского языка.
- **Размер модели:** ~3 ГБ (включая веса).
- **Количество параметров:** ~760–780 миллионов (версия Large).
- **Тип модели:** Языковая модель на основе трансформеров (Transformer), ориентированная на генерацию текста на русском языке.

Ресурсы для генерации и обучения

Локальный ПК +GPU




Удаленный сервер без GPU




**Основными для
обучения стали
синтетитические
данные**




Интерфейс LM Studio



Интерфейс LM Studio




Вид файла структуры курса




Content of the JSON file:

```
{
  "темы_машинного_обучения_на_русском": {
    "установка_и_настройка_Python": {
      "установка_Python_и_pip": [],
      "настройка_окружения": {
        "virtualenv": [],
        "conda": []
      },
      "использование_пакетного_менеджера": {
        "pip": []
      },
      "редакторы_кода": {
        "IDLE": [],
        "PyCharm": [],
        "Jupyter_Notebook": []
      }
    },
    "основы_Python": {
      "синтаксис_и_типы_данных": [],
      "структуры_данных": {
        "списки": [],
        "кортежи": [],
        "словари": [],
        "множества": []
      }
    }
  }
}
```

Использование ролевых промптов




2 : Scchollarily ia Fool



2: Graduattta Student



Graddemiandan



4:Dumb Gradue Studint

Очень мощный и полезный инструмент, позволяющий сориентировать модель на ответ в определённом формате

В то же время это может привести к замусориванию данных наименованиями, указанными в ролевых промптах, и утрате тематической метки ответа. Требуется тонкая настройка как самого промпта, так и обработки ответа

Синтетический датасет

	Тема	Метка класса	Объяснение и код
0	темы_машинного_обучения_на_русском/установка_и...	good	Python – это язык программирования, обладающий...
1	темы_машинного_обучения_на_русском/установка_и...	bad	🚫\n\n### Установка Python и Pip\n\n**Шаг 1: Ск...
2	темы_машинного_обучения_на_русском/установка_и...	good	Без них ты не сможешь использовать ни один из ...
3	темы_машинного_обучени	🔗	Первые 5 записей из файла generated_materials.jsonl:
4	темы_машинного_обучени		{
5	темы_машинного_обучени		"topic": "установка_Python_и_pip",
6	темы_машинного_обучени		"subtopic": "Установка Python на Linux",
7	темы_машинного_обучени		"material": "***Вопрос:** Как установить Python на Linux?\n\n**Ответ:**\n\nДля установки Python на Linux можно и
8	темы_машинного_обучени		}
9	темы_машинного_обучени		{
			"topic": "кортежи",
			"subtopic": "Создание",
			"material": "***Вопро
			"тема": "virtualenv: Активация виртуального окружения",
			"вопросы": [
			"Как можно установить Python на Linux, используя менеджер пакетов?",
			"Какие преимущества использования pip для установки Python?",
			"Как проверить, установлен ли Python версия, которую вы хотите?",
			"Какие действия нужно выполнить, чтобы использовать Python из командной строки",
			"Как можно установить дополнительную библиотеку Python?",
			"Как можно написать Python-скрипт?",
			"Как можно запустить Python-скрипт?",
			"Какие инструменты можно использовать для дебагинга Python-кода?",
			"Как можно оптимизировать производительность Python-скриптов?",
			"Какие из наиболее распространенных инструментов для работы с Python на Linux?",
			]
			}
			{
			"topic": "синтаксис_
			"subtopic": "Перемен
			"material": "***Вопро
			}
			{
			"topic": "virtualenv
			"subtopic": "Создани
			"material": "***Вопро
			}
			{

Проблема остановки обучения




How much more al
need to learn?

Подходы:

- дать модели
познакомиться со всеми
данными
- (в предельном случае
дать модели
переобучиться)
- настроить один из вариантов
ранней остановки

Параметры обучения лучшей модели



- кросс-валидация 5 фолдов
- batch size 4
- стратегия оценки каждые 10 шагов
- запланировано 30 эпох
- ранняя остановка по eval loss (early_stopping patience =2)

Подбор гиперпараметров

- Вариативность датасетов (книги, блокноты, синтетические датасеты уроков, синтетический датасет вопросов и ответов) от нескольких килобайт до 150 МБ в связи с этим приходилось менять следующие параметры:
 - - Размер батча от 1 до 8.
 - - Количество эпох от 3 до 30 с использованием или без использования ранней остановки.
 - - Подача данных с кросс-валидацией и без неё.

Итоги обучения




Ранняя остановка сработала после 2-х эпох.

Eval loss перестала улучшаться после 2-х шагов

Итоги обучения

Step
Loss over Epochs



В качестве лучшей выбрана одна из ранних моделей обученных на удаленном сервере так как по итогам сравнения путем общения последующие модели не смогли показать значительного улучшения

Итоги обучения

- Модель последовательно обучена на различных типах данных:
- - сгенерированные уроки (несколько вариантов)
- - вопросы-ответы
- - ноутбуки
- - вопросы-ответы

Итоги обучения

- Модель хорошо усваивает стилистику, в некоторых случаях возвращает короткие фрагменты кода или структуры подобные программному коду.
- Добиться желаемой точности в ответах модели не удалось

Трудности


**Значительная часть обучения
прошла при настройках, в которых
большая часть текстовой
информации не попадала в
модель.**

После устранения данной проблемы обучение фактически потеряло смысл так как для обучения на 150 Мб. данных на сервере без Cuda может потребоваться 50-60 дней непрерывных вычислений или 20 дней на 2x Tesla T4



Вывод

С учетом ограниченных ресурсов, которыми я располагал для обучения модели и потенциала модели GPT-3RU считаю задачу обучения модели в целом выполненной



Полезный опыт

Опыт настройки и запуска Guda под
Ubuntu и Windows -10

Работа на многопоточном удаленном
сервере.

Создано 7 датасетов

Модель 10 раз прошла обучение



UNIVERSITY
OF ARTIFICIAL
INTELLIGENCE

Спасибо за внимание!

Кочетков Михаил
E-mail: subaka@mail.ru
@KMN_MIFI

